



# SAĞLIKTA YAPAY ZEKÂ YARIŞMALARI PROJE SUNUŞ RAPORU

(Bilgisayarlı Görüyle Hastalık Tespiti Kategorisi)

Takım Seviyesi: Lisans

Takım Adı: Mediget

Takım ID: 553394

Başvuru ID: 2202394

# İçindekiler

1. Takım Şeması .....	3	2. Probleme
En Yakın Çözüm Sunan Uluslararası Makalelerin Özeti .....	3	3. Kullanılması
Planlanan Algoritmalar .....	5	4. Kullanılması
Planlanan Donanımlar ve Özellikleri .....	6	5. Özgünlük
.....	6	6. Proje Planı ve Takvimi
.....	7	7. Referanslar
.....	7	

# TakımŞeması

Takım Kaptanı

Genel proje yönetimi

Ekip üyeleri arasında iletişimi düzenleme

Proje hedeflerini belirleme ve takip etme

Gerekli kaynakları yönetme

Veterinerlik 3. Sınıf Öğrencisi

Veri setini oluşturma ve toplama süreçlerini organize etme

Veri setindeki görsellerin kalitesini kontrol etme

Veri setindeki anlamlı özellikleri belirleme

Bilgisayar Müh. 2. Sınıf Öğrencisi

Yapay zeka modelini eğitmek için kullanılacak

algoritmaları seçme

Modelin başlangıç aşamasında eğitilmesini sağlama

Modelin performansını izleme ve geliştirme stratejileri oluşturma

Bilgisayar Müh. 1. Sınıf Öğrencisi

Yapay zeka modelinin eğitiminde operatörlük yapma

Ekip içi ve dışı iletişimi koordine etme

Proje sürecini belgeleme

Endüstri Müh. 1. Sınıf Öğrencisi

Eğitilen modelin performansını değerlendirme ve test etme

Modelin doğruluğunu ve güvenilirliğini kontrol etme

Gerekirse modeli yeniden eğitmek için geri bildirim sağlama

## Probleme En Yakın Çözüm Sunan Uluslararası Makalelerin Özeti

### Derin Öğrenme Tabanlı Yöntemlerle Meme Kanseri Teşhisi: Sistematik Bir İnceleme ve Gelecek Yönelimler

Meme kanseri, kadınlarda ve nadiren erkeklerde görülen en yaygın kanser türlerinden biridir. Erken teşhis, tedavi ve sağkalım oranlarını önemli ölçüde artırabilir. Son yıllarda, yapay zeka ve derin öğrenme teknikleri, tıbbi teşhis ve tedavi alanında çığır açan gelişmeler sağlamıştır. Bu makale, Maged Nasser ve Umi KalsomYusoftarafındankalemealınmışolup,memekanseriteşhisiçinöğrenme temelli yöntemleri sistematik bir şekilde inceleyerek, mevcut durumu ve gelecek yönelimleri ele almaktadır.

Makale, derin öğrenmenin temel prensiplerini ve meme kanseri teşhisi gibi karmaşık bir tıbbi problemin ele alınmasında neden etkili olabileceğini açıklamaktadır. Derin öğrenme, büyük veri setlerinden öğrenme yeteneğine sahip karmaşık yapay sinir ağları kullanarak, karmaşık desenleri ve ilişkileri tanımlamak için ideal bir yöntemdir. Bu nedenle, meme kanseri teşhisi gibi çok boyutlu ve dinamik bir problemi ele almak için uygun bir adaydır.

Makale ayrıca, literatürdeki mevcut araştırmaları detaylı bir şekilde inceler. Farklı derin öğrenme modellerinin (örneğin, derin sinir ağları, konvolüsyonel sinir ağları, ve rekürrent sinir ağları) meme kanseri teşhisindeki etkinliğini ve bu yöntemlerin avantajlarını ve dezavantajlarını ele alır. Ayrıca, derin öğrenme tekniklerinin meme kanseri teşhisindeki başarı oranlarını artırmak için kullanılabilecek çeşitli yaklaşımları ve yöntemleri de inceler.

Yazarlar, mevcut araştırmalardan elde edilen bulguları özetler ve gelecek araştırmalar için önerilerde bulunur. Öneriler arasında, daha büyük ve çeşitli veri setlerinin kullanılması, derin öğrenme modellerinin daha iyi ölçeklendirilmesi, ve klinik uygulamalara yönelik daha fazla odaklanma yer almaktadır. Ayrıca, derin öğrenme tekniklerinin meme kanseri teşhisindeki potansiyelini tam olarak gerçekleştirmek için daha fazla multidisipliner çalışma ve işbirliğinin gerekliliği vurgulanmaktadır.

Sonuç olarak, bu makale, derin öğrenme tabanlı yöntemlerin meme kanseri teşhisindeki mevcut durumunu ve gelecek yönelimlerini sistemli bir şekilde ele almaktadır. Bu alandaki ilerlemeler, meme kanseri teşhisi, tedavisi ve yönetiminde büyük faydalar sağlayabilir ve derin öğrenme teknikleri, bu alandaki önemli ihtiyaçları karşılamak için önemli bir araç olabilir.

## Meme Kanseri Riskinin Mamografik Fenotiplemesinde Yapay Zeka: Anlatısal Bir İnceleme

Randomize çalışmalar ve tarama kohort çalışmaları, rutin, mamografik taramanın meme kanseri morbidite ve mortalitesinde azalma ile ilişkili olduğunu açıkça göstermiştir [1]. Başlangıçta, meme kanseri taraması analog ekran-film tabanlı mamografi sistemleriyle yapıldı, ancak son 20 yılda mamografik tarama, pikseli verilerin dijital meme tomosentezinin (DBT) yarı 3D formatına yeniden yapılandırılmasına izin veren tamamen dijital platformlara (tam alan dijital mamografi (FFDM)) geçiş yaptı [2].

Klinik ortamda meme yoğunluğunu değerlendirmek için en sık kullanılan yöntem, Amerikan Radyoloji Koleji (ACR) Meme Görüntüleme-Raporlama ve Veri Sistemi (BIRADS) tarafından özetlenen 4 kategoriden birine yorumlayıcı radyolog tarafından

meme yoğunluğunun görsel ve subjektif olarak derecelendirilmesidir [20]. Bununla birlikte, meme yoğunluğunun atanmasında, özellikle daha az deneyimli okuyucular arasında, 0.4 ila 0.7 arasında değişen  $\kappa$  istatistikleri ile büyük ölçüde okuyucular arası ve okuyucu içi değişkenliğin olduğu iyi bilinmektedir [21].

Son zamanlarda, yapay zekâ destekli BI-RADS meme yoğunluğu değerlendirmesine yönelik önemli bir adım olabilecek araştırma, DBT alımlarından yeniden yapılandırılan 2D sentetik mamografik (SM) görüntüleri kullanan DL modelleri oluşturmak için alan adaptasyon yaklaşımlarından yararlanmaya odaklandı. Bu yaklaşımın fizibilitesi, uyarlanan modelin radyologlar tarafından SM görüntülerinden BI-RADS yoğunluk sınıflandırması ile iyi bir uyum sağladığı iki klinik bölgeden büyük, ırksal olarak çeşitli veri kümelerinde gösterilmiştir (dört sınıf  $K = 0.72-0.79$ ) [26]. Bu alandaki ek yeni yönler arasında son teknoloji DL mimarilerini keşfetmek [27, 28] ve katılımcı kurumların gerçek görüntüler yerine model ağırlıklarını kendi aralarında paylaştığı birleşik öğrenmeyi kullanmak yer alıyor. İkinci yaklaşımın amacı, DL modellerini büyük çok kurumlu kohortlarla eğitmek ve geliştirmektir [35].

Ek çalışmalar [43,44,45,46,47], meme kanseri tanısından en az bir yıl önce elde edilen normal mamografik görüntülerle veya negatif (yani, BIRADS 1 veya 2) takip (Tablo 2). Bu çalışma tasarımları, klinik olarak, gerçek bir kanser teşhisi konmadan önce yüksek riskli kadınları tanımlamayı amaçladığı anlamında, meme kanseri risk değerlendirmesinin görevini kavramsal olarak daha iyi yansıtmaktadır (Şek. 4). Ayrıca, böyle bir çalışma tasarımında, aynı yaştaki meme kanseri vakalarını ve kontrollerini kullanmak veya yaşa göre ayarlanmış değerlendirme önlemlerini rapor etmek önemlidir, aksi takdirde risk tahmininin şişirilmiş performans tahminleri ortaya çıkabilir. Sunulan modeller, 0.60 ila 0.84 arasında değişen EAA'larla umut verici performanslar sergilemiştir ve genellikle son teknoloji meme kanseri risk modellerinden daha iyi performans göstermiştir [43, 44]. Örneğin, Ha ve ark. [47], FFDM güdümlü bir DL risk skorunun BI-RADS meme yoğunluğundan daha büyük bir öngörücü potansiyele sahip olduğunu bulmuşlardır (sırasıyla 4.4'e karşı 1.7 olasılık oranları). Dombrower ve ark. [43], FFDM kaynaklı DL risk skorlarının otomatik meme yoğunluğu ölçümlerinden daha iyi performans gösterdiğini bildirmiştir (sırasıyla 1.6 ve 1.3 olasılık oranları). Son olarak, Yala ve ark. [44], mamografik DL risk skorunun klinik uygulamada kullanılan Tyrer-Cuzick modelinden daha iyi performans gösterdiğini göstermiştir (EAA sırasıyla 0.68'e karşı 0.62). Toplu olarak, bu çalışmalar, FFDM tabanlı DL modellerinin, yoğunluğa dayalı modellere ve mevcut epidemiyoloji tabanlı modellere göre meme kanseri riskinin daha doğru belirleyicileri olarak umut vaat ettiğine dair ön kanıtlar sunmaktadır.



## Kullanılması Planlanan Algoritmalar

Takımımız Keras kütüphanesi hakkında özellikle donanımlıdır. Keras ile uyumlu olan ve 2023'te çıkan YOLOv8 algoritması kullanılacaktır. Çeşitli algoritmalar araştırılmış, nesne tanıma ve hız arasında optimal bir denge sunan açık kaynaklı YOLOv8 algoritmasının en uygun seçenek olduğu görülmüştür.

## Kullanılması Planlanan Donanımlar ve Özellikleri

Takımın her üyesinin uzaktan erişmesini sağlaması ve güçlü GPU'larla çalışmaya olanak tanımasından dolayı bulut hizmetleri üzerinde durulmuştur. Google Colab, Amazon Web Services (AWS) ve Microsoft Azure gibi servisler hakkında araştırma yapıp, verim açısından en iyi seçeneğin Google Colab olduğu görülmüştür.

## Özgünlük

YOLOv8 algoritmasıyla Keras arayüzünü birleştiren bir çalışma yapacağız. Yalnızca YOLOv8 değil aynı zamanda farklı yapay sinir ağı algoritmalarının da katkı sunacağı çalışmamızda bize verilecek veri setini çoğaltmak için de planlarımız var. Verileri çoğaltmak için kontrast, parlaklık ve keskinlik değerlerini değiştirmenin yanında bulanıklık değerleriyle de oynayarak veri setini genişletip modelin doğruluğunu artırma yolunda önemli bir adım atmış olacağız.

## Proje Planı ve Takvimi

	Nisan	Mayıs	Haziran	Temmuz	Ağustos
Literatür Taraması	✓	✓	✓	✓	
Veri Setine Erişim ve Verilerin Sınıflandırılması	✓				
Verilerle Model Eğitimi		✓	✓		
Test Modeli			✓	✓	
Modelin Oluşturulması				✓	✓

# REFERANSLAR

1. Pace LE, Keating NL. Meme kanseri tarama kararlarına rehberlik etmek için faydaların ve risklerin sistematik bir değerlendirmesi. JAMA. 2014; 311(13):1327–35.
2. Sechopoulos I. Meme tomosentezinin gözden geçirilmesi. Bölüm I. Görüntü elde etme süreci. Tıp Fiz. 2013; 40(1):014301.
6. Conant EF, Sprague BL, Kontos D. BI-RADS yoğunluğunun ötesinde: meme görüntüleme kliniğinde nicelleştirme çağrısı. Radyoloji. 2018; 286(2):401–4.
7. Gastounioti A, Conant EF, Kontos D. Meme yoğunluğunun ötesinde: meme kanseri risk değerlendirmesinde parankimal doku analizinin ilerleyen rolü üzerine bir inceleme. Meme Kanseri Arş. 2016; 18(1):91.
8. Litjens G, Kooi T, Bejnordi BE, Setio AAA, Ciompi F, Ghafoorian M, Van Der Laak JA, Van Ginneken B, Sánchez CI. Tıbbi görüntü analizinde derin öğrenme üzerine bir araştırma. Med Görüntü Anal. 2017; 42:60–88.
9. Bertsimas D, Wiberg H. Onkolojide makine öğrenimi: yöntemler, uygulamalar ve zorluklar. JCO Klinik Kanser Bilgilendirmesi. 2020; 4:885–94.
20. D'Orsi CJ. ACR BI-RADS atlası: meme görüntüleme raporlama ve veri sistemi. Reston: Amerikan Radyoloji Koleji; 2013.
21. Sprague BL, Conant EF, Onega T, Garcia MP, Beaber EF, Herschorn SD, Lehman CD, Tosteson AN, Lacson R, Schnall MD. Klinik uygulamada radyologlar arasında mamografik meme yoğunluğu değerlendirmelerindeki varyasyon: çok merkezli bir gözlemsel çalışma. Ann Stajyer Med. 2016; 165(7):457–64.
26. Matthews TP, Singh S, Mombourquette B, Su J, Şah Milletvekili, Pedemonte S, Uzun A, Maffit D, Gurney J, Morales Hoil R. Tam alan dijital mamografi görüntüleri ve sentetik mamografi görüntüleri için meme yoğunluğu derin öğrenme modelinin çok bölgeli bir çalışması. Radyol Artif Intell. 2020; 3:E200015 (İngilizce).
27. Saffari N, Rashwan HA, Abdel-Nasser M, Kumar Singh V, Arenas M, Mangina E, Herrera B, Puig D. Derin öğrenme kullanarak tam otomatik meme yoğunluğu segmentasyonu ve sınıflandırması. Tanılama. 2020; 10(11):988.
28. Deng J, Ma Y, Li D, Zhao J, Liu Y, Zhang H. SE-dikkat sinir ağlarına dayalı meme yoğunluğu kategorilerinin sınıflandırılması. Hesaplama Yöntemleri Programları Biyomedik. 2020;193:105489.
35. Roth HR, Chang K, Singh P, Neumark N, Li W, Gupta V, Gupta S, Qu L, Ihsani A, Bizzo BC ve diğerleri. Meme yoğunluğu sınıflandırması için birleşik öğrenme: gerçek dünya uygulaması. İçinde: Albarqouni S, et al., editörler. Alan adaptasyonu ve temsil aktarımı, dağıtılmış ve işbirlikçi öğrenme. Cham: Yaylı; 2020. sayfa 181–91.
36. Kallenberg M, Petersen K, Nielsen M, Ng A, Diao P, Igel C, Vachon C, Holland K, Karssemeijer N, Lillholm M. Meme yoğunluğu segmentasyonu ve mamografik risk puanlamasına uygulanan denetimsiz derin öğrenme. IEEE Trans Med Görüntüleme. 2016; 35(5):1322–31.
41. Li H, Giger ML, Huynh BQ, Antropova NO. Meme kanseri risk değerlendirmesinde derin öğrenme: tam alan dijital mamogramların klinik veri kümesinde evrimsel sinir ağlarının değerlendirilmesi. J Med Görüntüleme. 2017; 4(4):041304.
42. Gastounioti A, Oustimov A, Hsieh M-K, Pantalone L, Conant EF, Kontos D. Meme kanseri riski ile ilişkili meme parankimal karmaşıklık paternlerinin daha iyi yakalanması için evrimsel sinir ağlarının kullanılması. Acad Radyol. 2018; 25:977–84.
43. Dembrower K, Liu Y, Azizpour H, Eklund M, Smith K, Lindholm P, Strand F. Meme kanseri risk tahmini için derin öğrenme risk puanı ile standart